

Clasificar dígitos con contexto local


Softmax vs. Graph-MLP · MNIST

Diego Díaz · Bairon Horna · Ignacio Marín · Jordan López · Aaron Medrano

Los trazos importan más que los píxeles aislados

Una imagen es una red

Cada píxel es un nodo. Las aristas conectan ocho vecinos. El patrón útil está en la continuidad del trazo.



En Costa Rica podría apoyar la transcripción de formularios y registros; MNIST solo es una prueba de concepto.

La pregunta es comparativa, no promocional

¿Incorporar vecindad local y una frontera no lineal mejora la clasificación frente a un modelo lineal?

1

Representar

MNIST como grafo de 784 nodos

2

Comparar

Softmax y Graph-MLP en los mismos datos

3

Validar

F1 macro, pérdida y tres pliegues

4

Tensionar

L2, propagación y tamaño muestral

70,000 imágenes; la prueba oficial queda cerrada

Variable	Forma	Rango	Uso
x_train	60,000×28×28	0–255 → [0,1]	Ajuste / CV
y_train	60,000	0–9	Etiqueta
x_test	10,000×28×28	0–255 → [0,1]	Prueba final
y_test	10,000	0–9	Referencia

1.24×

clase mayor / menor

2026



semilla fija

Sin faltantes, sin imputación y sin usar etiquetas durante la propagación.

Las clases están balanceadas y los trazos conservan geometría

MNIST contiene trazos diversos dentro de cada clase

Muestra estratificada del conjunto de entrenamiento; intensidades normalizadas a [0, 1].



La clase 1 tiene 6,742 ejemplos; la 5, 5,421. Las diagonales justifican ocho vecinos.

Dos pasos mezclan señal propia y vecindad

$$H(t+1) = (1 - \alpha)H(t) + \alpha D^{-1} A H(t)$$

$H(0)$

Intensidad del píxel

$D^{-1}AH$

Promedio de ocho
vecinos

$\alpha = 0.35$

Conserva 65%
propio

$T = 2$

Evita
sobre-suavizado

El prototipo original usó `einsum('nn,...')`: tomó la diagonal nula de A y eliminó todos los mensajes.

Los modelos parten de supuestos distintos

Softmax

Frontera lineal

- 784 intensidades
- 7,850 parámetros
- $L2 = 10^{-4}$
- Adam, lr = 0.002

Graph-MLP

Contexto local + ReLU

- Propagación $T = 2$
- 64 unidades ocultas
- $\approx 50,900$ parámetros
- Adam, lr = 0.001

Ambos: 12 épocas · lotes de 256 · semilla 2026

La comparación usa los mismos pliegues y la misma prueba



Métrica principal: F1 macro · Apoyo: exactitud, precisión, exhaustividad y log-loss

Graph-MLP gana 3.31 puntos de F1 en prueba

Modelo	CV F1 macro	Exactitud	F1 prueba	Log-loss
Softmax	89.02% $\pm$ 0.22	92.30%	92.19%	0.280
Graph-MLP	91.32% $\pm$ 0.39	95.56%	95.51%	0.152

+3.31

puntos de F1

-45.7%

pérdida logarítmica


3 / 3

pliegues favorables

4 ↔ 9 sigue siendo la confusión más persistente

Graph-MLP: menos errores

Filas: clase real. Columnas: clase predicha. Cada fila está normalizada.



Lectura

9 → 4: 28 casos

8 → 5: 21 casos

8 → 3: 19 casos

7 → 2: 17 casos

Errores principales

4 → 9 28 casos


9 → 4 28 casos

8 → 5 21 casos

3 → 5 15 casos

La clase 5 mejora de 88.8% a 95.1% de aciertos.

Más datos ayudan; más propagación termina suavizando de más



L2 es estable

92.51% → 92.37%

T = 0 supera T = 3

92.73% → 92.21%

La no linealidad aporta más que el suavizado fijo.

Conclusión: el modelo es robusto a L2, pero frágil cuando faltan datos.

95.5% en MNIST no autoriza una decisión real

Limitaciones

- Dígitos centrados y limpios
- Sin escritura costarricense
- Propagación fija, no GNN aprendible
- Comparación mezcla grafo y no linealidad
- Sin auditoría demográfica

Salvaguardas

- Validación local por fuente
- Umbral de rechazo
- Revisión humana
- Conservación de imagen original
- Monitoreo de deriva y subgrupos

La siguiente inversión debe ser en datos locales, no en más capas

Conclusión

Graph-MLP mejora F1 y log-loss, pero la ablación muestra que la no linealidad aporta más que la propagación fija.

Recomendación

Recolectar 1,000–5,000 dígitos costarricenses, comparar MLP/CNN/GNN con capacidad equivalente y fijar revisión humana.

Un prototipo útil no es el que nunca falla; es el que sabe cuándo pedir ayuda.

Respaldo · métricas completas y variabilidad

Modelo	CV exactitud	CV F1	Prueba precisión	Prueba recall	Prueba log-loss
Softmax	89.06% $\pm$ 0.22	89.02% $\pm$ 0.22	92.19%	92.22%	0.280
Graph-MLP	91.35% $\pm$ 0.39	91.32% $\pm$ 0.39	95.52%	95.52%	0.152

La desviación estándar entre pliegues es menor a 0.4 puntos para ambos modelos.

Semilla 2026 · CV estratificada · mismos índices · prueba oficial intacta

Respaldo · qué se corrigió y cómo reproducir

Error original

`einsum('nn,bnf→bnf')`
seleccionaba $\text{diag}(A) = 0$

Corrección

Suma de ocho vecinos
+ normalización por grado

Orden de ejecución

[01_exploracion.ipynb](#) → [02_modelos.ipynb](#) → [03_validacion.ipynb](#)

Sin rutas personales · datos incluidos · NumPy · README · LICENSE