

Clasificar dígitos con contexto local


Prototipo OCR · Softmax vs. Graph-MLP

Diego Díaz · Bairon Horna · Ignacio Marín
Jordan López · Aaron Medrano · Emilio de Gomez

Fechas, folios y montos dependen de trazos completos

Un dígito es una red

Cada píxel es un nodo. Las aristas conectan ocho vecinos. El patrón útil está en la continuidad del trazo.



Aplicación propuesta: protocolos, formularios y expedientes en papel. MNIST es solo el banco de prueba.

El prototipo se evalúa antes de tocar un expediente

¿El contexto local mejora el reconocimiento de dígitos y qué falta para validarlo en archivos públicos?

1

Representar

Dígitos como grafos de 784 nodos

2

Comparar

Softmax y Graph-MLP bajo la misma prueba

3

Validar

F1, pérdida y validación común

4

Tensionar

L2, propagación, datos y controles

70,000 imágenes; la prueba oficial queda cerrada

Variable	Forma	Rango	Uso
x_train	60,000×28×28	0–255 → [0,1]	Ajuste / CV
y_train	60,000	0–9	Etiqueta
x_test	10,000×28×28	0–255 → [0,1]	Prueba final
y_test	10,000	0–9	Referencia

1.24×

clase mayor / menor

2026



semilla fija

Sin faltantes, sin imputación y sin usar etiquetas durante la propagación.

Las clases están balanceadas y los trazos conservan geometría

MNIST contiene trazos diversos dentro de cada clase

Muestra estratificada del conjunto de entrenamiento; intensidades normalizadas a [0, 1].



La clase 1 tiene 6,742 ejemplos; la 5, 5,421. Las diagonales justifican ocho vecinos.

Dos pasos mezclan señal propia y vecindad

$$H(t+1) = (1 - \alpha)H(t) + \alpha D^{-1} A H(t)$$

$H(0)$

Intensidad del píxel

$D^{-1}AH$

Promedio de ocho
vecinos

$\alpha = 0.35$

Conserva 65%
propio

$T = 2$

Evita sobre-
suavizado

El prototipo original usó `einsum('nn,...')`: tomó la diagonal nula de A y eliminó todos los mensajes.

Los modelos parten de supuestos distintos

Softmax

Frontera lineal

- 784 intensidades
- 7,850 parámetros
- $L2 = 10^{-4}$
- Adam, lr = 0.002

Graph-MLP

Contexto local + ReLU

- Propagación $T = 2$
- 64 unidades ocultas
- $\approx 50,900$ parámetros
- Adam, lr = 0.001

Ambos: 12 épocas · lotes de 256 · semilla 2026

La comparación usa los mismos pliegues y la misma prueba



Métrica principal: F1 macro · Apoyo: exactitud, precisión, exhaustividad y log-loss

Graph-MLP gana 3.31 puntos de F1 en prueba

Modelo	CV F1 macro	Exactitud	F1 prueba	Log-loss
Softmax	89.02% $\pm$ 0.22	92.30%	92.19%	0.280
Graph-MLP	91.32% $\pm$ 0.39	95.56%	95.51%	0.152

+3.31

puntos de F1

-45.7%

pérdida logarítmica


3 / 3

pliegues favorables

4 ↔ 9 sigue siendo la confusión más persistente

Graph-MLP: menos errores

Filas: clase real. Columnas: clase predicha. Cada fila está normalizada.



Lectura

9 → 4: 28 casos

8 → 5: 21 casos

8 → 3: 19 casos

7 → 2: 17 casos

Errores principales

4 → 9 28 casos

9 → 4 28 casos

8 → 5 21 casos

3 → 5 15 casos

La clase 5 mejora de 88.8% a 95.1% de aciertos.

Más datos ayudan; más propagación termina suavizando de más



L2 es estable

92.51% → 92.37%

T = 0 supera T = 3

92.73% → 92.21%

La no linealidad aporta más que el suavizado fijo.

Conclusión: el modelo es robusto a L2, pero frágil cuando faltan datos.

95.5% en MNIST no autoriza migrar un archivo

Limitaciones

- Dígitos centrados y limpios
- Sin escritura costarricense
- Propagación fija, no GNN aprendible
- Comparación mezcla grafo y no linealidad
- Sin auditoría demográfica

Salvaguardas

- Validación local por fuente
- Umbral de rechazo
- Revisión humana
- Conservación de imagen original
- Monitoreo de deriva y subgrupos

La siguiente inversión debe ser en archivos locales etiquetados

Conclusión

Graph-MLP mejora F1 y log-loss en MNIST; todavía no demuestra fidelidad sobre documentos públicos.

Recomendación

Etiquetar 1,000–5,000 recortes de una serie pública, comparar modelos y exigir revisión humana.

Digitalizar no es borrar el papel: es preservar, transcribir y poder auditar.

Respaldo · métricas completas y variabilidad

Modelo	CV exactitud	CV F1	Prueba precisión	Prueba recall	Prueba log-loss
Softmax	89.06% ± 0.22	89.02% ± 0.22	92.19%	92.22%	0.280
Graph-MLP	91.35% ± 0.39	91.32% ± 0.39	95.52%	95.52%	0.152

La desviación estándar entre pliegues es menor a 0.4 puntos para ambos modelos.

Semilla 2026 · CV estratificada · mismos índices · prueba oficial intacta

Respaldo · corrección, reproducción y alcance archivístico

Error original

`einsum('nn,bnf→bnf')`
seleccionaba `diag(A) = 0`

Corrección

Suma de ocho vecinos
+ normalización por grado

Orden de ejecución

[01_exploracion.ipynb](#) → [02_modelos.ipynb](#) → [03_validacion.ipynb](#)

Sin rutas personales · datos incluidos · README · LICENSE · revisión humana